针孔相机模型

原始模型：小孔成像

相机坐标系到像素坐标系

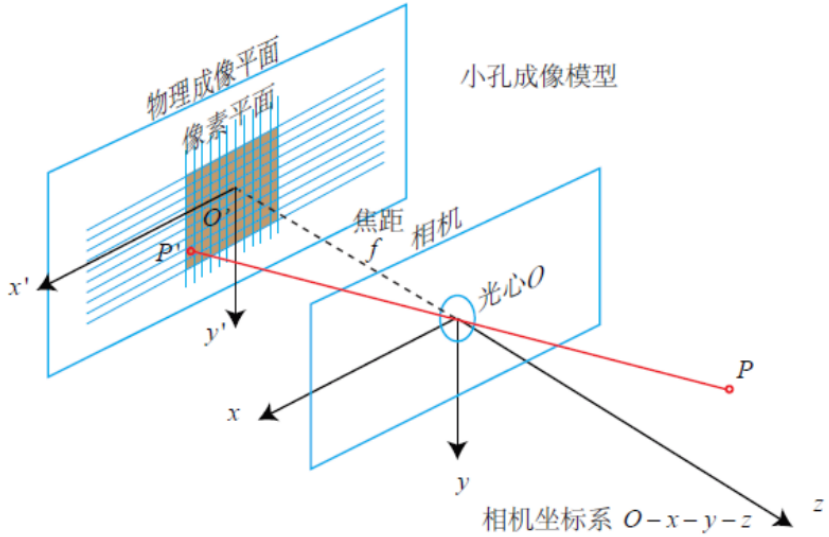

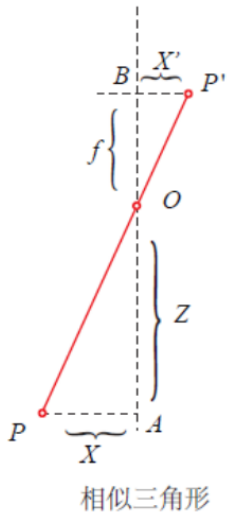

$$\frac{Z}{f}=\frac{X}{X'}=\frac{Y}{Y'}$$

$$X'=f\frac{X}{Z}\quad Y'=f\frac{Y}{Z}$$

下面将成像平面投影到像素坐标：

$$u=\alpha X'+c_x,\quad v=\beta Y'+c_y$$

整理可得：

$$\begin{cases}u=f_x\frac{X}{Z}+c_x\\ v=f_y\frac{Y}{Z}+c_y\end{cases}$$

进而可以写成由齐次坐标形式到非齐次坐标的转换公式：

$$Z\begin{pmatrix}u\\v\\1\end{pmatrix}=\begin{pmatrix}f_x&0&c_x\\0&f_y&c_y\\0&0&1\end{pmatrix}\begin{pmatrix}X\\Y\\Z\end{pmatrix}\triangleq\boldsymbol{KP}$$

中间的矩阵被称为**相机内参矩阵**，内参通常在相机生产后就已经固定。

相机坐标系到世界坐标系

相机坐标系只是一个坐标系，我们需要把三维世界中多个相机的拍照结果统一整合到一个坐标系中，即世界坐标系

$$Z\boldsymbol{P}_{uv}=Z\begin{bmatrix}u\\v\\1\end{bmatrix}=\boldsymbol{K}\left(\boldsymbol{R}\boldsymbol{P}_w+\boldsymbol{t}\right)=\boldsymbol{KTP}_w$$

> 上式中包含了一次齐次坐标到非齐次坐标的转换，即在$\boldsymbol{TP}$中使用齐次坐标，再转化成非齐次坐标并与$\boldsymbol{K}$相乘。

这里的R是一个3x3的旋转矩阵，t是一个3x1的平移矩阵，称为相机的**外参**。外参也有矩阵形式：

$$\begin{pmatrix} \boldsymbol{R} & \boldsymbol{t} \\ \boldsymbol{0}^3 & 1 \end{pmatrix} \triangleq \boldsymbol{T}$$

外参是SLAM估计的目标。

归一化坐标

投影的过程有另一种理解。我们可以把一个世界坐标点先转换到相机坐标系，再除以其最后一维的数值（**即该点距离相机成像平面的深度**），这相当于把最后一维进行**归一化处理**，得到点在相机**归一化平面**上的投影，即**归一化坐标**：

$$(\boldsymbol{R}\boldsymbol{P}_w + \boldsymbol{t}) = [X, Y, Z]^T \rightarrow [X/Z, Y/Z, 1]^T$$

归一化坐标左乘内参可以得到像素坐标。所以像素坐标可以理解成对归一化平面上的点进行量化测量的结果。

点的深度在投影的过程中是丢失的，因为对象极坐标同时乘上任何非零常数，归一化坐标都不变。即单目视觉无法测量深度。

畸变（失真）

畸变主要有两种类型：

- 径向畸变

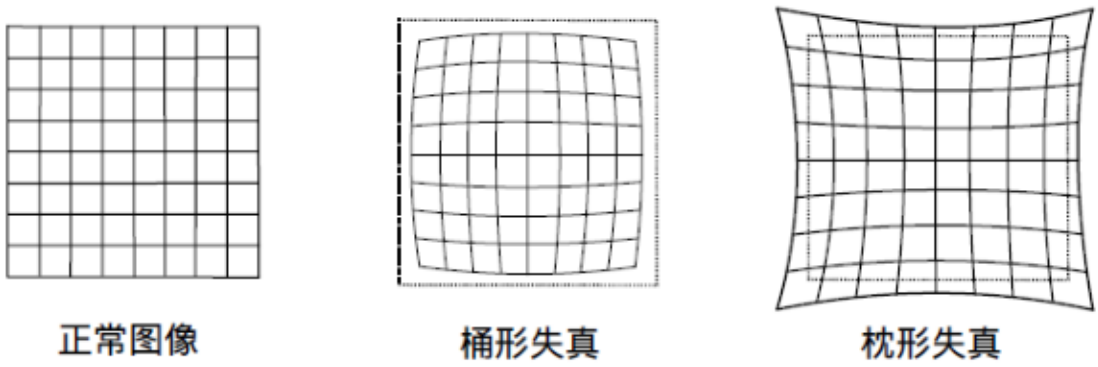

- 切向畸变

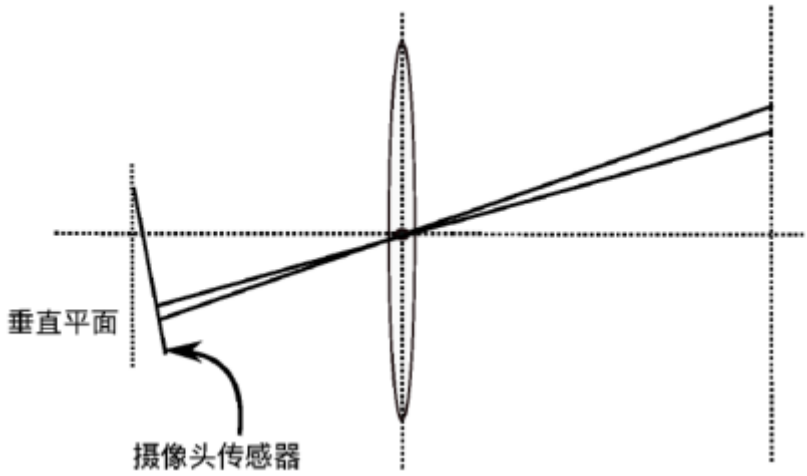

畸变模型可以用归一化坐标的变换来描述。下式中每个坐标的畸变公式的左右两部分分别代表径向和切向畸变。

$$
\begin{cases} x_{\text{distorted}} &= x\left(1+k_1r^2+k_2r^4+k_3r^6\right)+2p_1xy+p_2\left(r^2+2x^2\right) \\ y_{\text{distorted}} &= y\left(1+k_1r^2+k_2r^4+k_3r^6\right)+p_1\left(r^2+2y^2\right)+2p_2xy \end{cases}
$$

双目相机模型

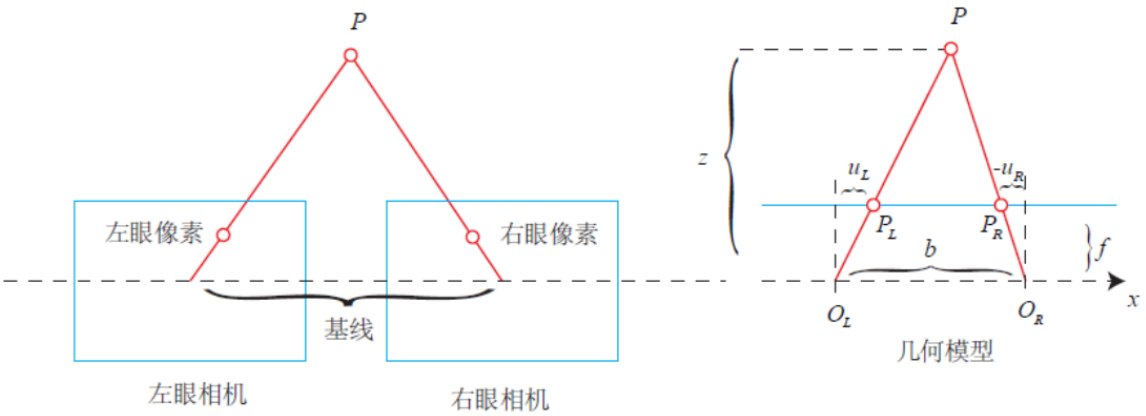

$$
\frac{z-f}{z}=\frac{b-u_L+u_R}{b}
$$

$$
z=\frac{fb}{d}, \quad d=u_L-u_R
$$

其中d为视差，描述同一个点在左右目上城乡的距离，最小为一个像素。因此可以得到双目可测距离z的最大值fb。

状态估计问题

回顾SLAM的经典模型：

$$
\begin{cases} \boldsymbol{x}_k = f\left(\boldsymbol{x}_{k-1}, \boldsymbol{u}_k\right)+\boldsymbol{w}_k \\ \boldsymbol{z}_{k,j} = h\left(\boldsymbol{y}_j, \boldsymbol{x}_k\right)+\boldsymbol{v}_{k,j} \end{cases}
$$

其中的位姿可以用SE(3)描述，观测方程可以用相机模型表示。问题在于：给定模型和具体观测数据时，我们如何估计状态变量？

批量状态估计

- SLAM过程中的数据是随时间得到的，因此我们会持有一个当前时刻的估计状态，然后用新的数据来更新它。这种方式叫做**滤波器**或**增量方法**（incremental）。
- 把数据"攒"起来，一并处理。称为**批量方法**（batch）。

定义所有时刻的机器人位姿和路标点坐标为：

$$
\boldsymbol{x}=\{\boldsymbol{x}_1,\ldots,\boldsymbol{x}_N\}, \quad \boldsymbol{y}=\{\boldsymbol{y}_1,\ldots,\boldsymbol{y}_M\}
$$

用$\boldsymbol{u}$表示所有时刻的输入，$\boldsymbol{z}$表示所有时刻的观测数据，那么我们其实求的就是已知输入数据和观测数据的条件下，位姿和路标的条件概率分布：

$$
P(\boldsymbol{x},\boldsymbol{y}\mid\boldsymbol{z},\boldsymbol{u})
$$

> 特别地，当我们不知道控制输入，只有观测数据时，此问题叫做SfM（Structure from Motion），即如何从许多图像中重建三维空间结构

由贝叶斯法则：

$$
P(\boldsymbol{x},\boldsymbol{y}\mid\boldsymbol{z},\boldsymbol{u})=\frac{P(\boldsymbol{z},\boldsymbol{u}\mid\boldsymbol{x},\boldsymbol{y})P(\boldsymbol{x},\boldsymbol{y})}{P(\boldsymbol{z},\boldsymbol{u})}\propto P(\boldsymbol{z},\boldsymbol{u}\mid\boldsymbol{x},\boldsymbol{y})P(\boldsymbol{x},\boldsymbol{y})
$$

左侧称为**后验概率**，右侧左边称为**似然概率**，右边称为**先验概率**。

直接求后验概率非常难，但是我们可以由如下两步状态估计来及逆行预测：

- 最大后验估计（Maximize a Posterior，MAP）

$$(\boldsymbol{x}, \boldsymbol{y})_{MAP}^{*} = \arg\max P(\boldsymbol{x}, \boldsymbol{y} \mid \boldsymbol{z}, \boldsymbol{u}) = \arg\max P(\boldsymbol{z}, \boldsymbol{u} \mid \boldsymbol{x}, \boldsymbol{y}) P(\boldsymbol{x}, \boldsymbol{y})$$

  即求一个状态最有估计，使得在该状态下后验概率最大化。

- 最大似然估计（Maximize Likelihood Estimation, MLE）

$$(\boldsymbol{x}, \boldsymbol{y})_{MLE}^{*} = \arg\max P(\boldsymbol{z}, \boldsymbol{u} \mid \boldsymbol{x}, \boldsymbol{y})$$

  即在何种状态下，最可能产生现在观测到的数据。

最小二乘问题

下面考虑一个实际的需要解决的最大似然估计问题。

已知某次观测：

$$\boldsymbol{z}_{k,j} = h\left(\boldsymbol{y}_j, \boldsymbol{x}_k\right) + \boldsymbol{v}_{k,j}$$

噪声满足高斯分布：

$$\boldsymbol{v}_k \sim N\left(0, \boldsymbol{Q}_{k,j}\right)$$

则观测数据的条件概率仍为高斯分布，公式为：

$$P\left(\boldsymbol{z}_{j,k} \mid \boldsymbol{x}_k, \boldsymbol{y}_j\right) = N\left(h\left(\boldsymbol{y}_j, \boldsymbol{x}_k\right), \boldsymbol{Q}_{k,j}\right)$$

对于任意高维高斯分布$\boldsymbol{x} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$，它的概率密度函数展开为：

$$P(\boldsymbol{x}) = \frac{1}{\sqrt{(2\pi)^N \det(\boldsymbol{\Sigma})}} \exp\left(-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu})\right)$$

取负对数：

$$-\ln(P(\boldsymbol{x})) = \frac{1}{2}\ln\left((2\pi)^N \det(\boldsymbol{\Sigma})\right) + \boxed{\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu}).}$$

对于原函数求最大化，相当于对负对数求最小化。显然，我们只要最小化右侧的二次型，就可以得到对状态的最大似然估计。右边红色的二次型也成为马拉诺比斯距离，或**马氏距离**。

相当于，我们在求（把上面条件概率高斯分布展开取负对数的后半部分求最小）：

$$(\boldsymbol{x}, \boldsymbol{y})^{*} = \arg\min\left(\left(\boldsymbol{z}_{k,j} - h\left(\boldsymbol{x}_k, \boldsymbol{y}_j\right)\right)^T \boldsymbol{Q}_{k,j}^{-1}\left(\boldsymbol{z}_{k,j} - h\left(\boldsymbol{x}_k, \boldsymbol{y}_j\right)\right)\right)$$

这就是所谓的**最小二乘问题**（Least Square Problem），它的解等价于状态的最大似然估计。

通常，假设各个时刻的输入和观测相互独立，则可以独立地处理各个时刻的运动和观测。定义各输入和观测数据预模型之间的误差：

$$\begin{aligned} \boldsymbol{e}_{v,k} &= \boldsymbol{x}_k - f\left(\boldsymbol{x}_{k-1}, \boldsymbol{u}_k\right) \\ \boldsymbol{e}_{y,j,k} &= \boldsymbol{z}_{k,j} - h\left(\boldsymbol{x}_k, \boldsymbol{y}_j\right) \end{aligned}$$

那么最小化所有时刻估计值预真实读数之间的马氏距离，等价于求最大似然估计。根据负对数性质，可以将乘积化为求和，得到最小化误差的二范数：

$$\min J(\boldsymbol{x},\boldsymbol{y})=\sum_k e_{v,k}^T\boldsymbol{R}_k^{-1}e_{v,k}+\sum_k\sum_j e_{y,k,j}^T\boldsymbol{Q}_{k,j}^{-1}\boldsymbol{e}_{y,k,j}$$

其中$\boldsymbol{Q}_{k,j}^{-1}$也叫信息矩阵，它是高斯分布协方差矩阵的逆，也可以理解成为调节范数各分量之间的比例关系，即加权后的二范数。

非线性最小二乘

$$\min F(x)=\min\frac{1}{2}\|f(x)\|_2^2$$

思路：**迭代法**求解导函数为零

1. 给定初始值x_0
2. 对于第k次迭代，寻找一个增量Δx_k，使得$\|f\left(x_k+\Delta x_k\right)\|_2^2$达到极小值
3. 若增量足够小，则停止
4. 否则，加上这个增量进行下一步迭代

问题：如何寻找下降增量？

最速下降法

泰勒展开：

$$\|f(\boldsymbol{x}+\Delta\boldsymbol{x})\|_2^2\approx\|f(\boldsymbol{x})\|_2^2+\boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x}+\frac{1}{2}\Delta\boldsymbol{x}^T\boldsymbol{H}\Delta\boldsymbol{x}$$

我们只保留一节梯度（即雅可比矩阵），那么去增量为反向梯度则可以保证函数梯度下降（通常会制定步长）：

$$\Delta\boldsymbol{x}^*=-\boldsymbol{J}^T(\boldsymbol{x})$$

问题：过于贪心，容易出现zigzag路线

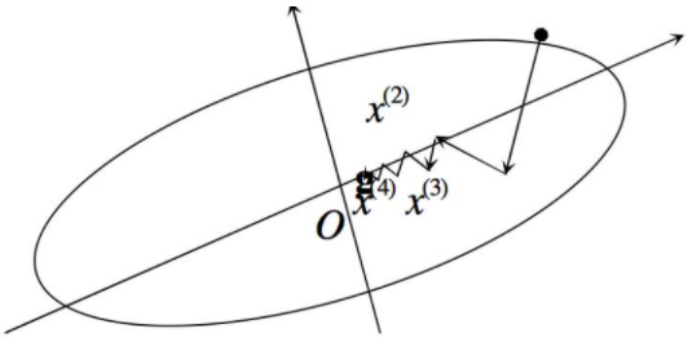

牛顿法

保留上式中的二阶梯度（即海塞矩阵），则增量方程为：

$$\Delta\boldsymbol{x}^*=\arg\min\|f(\boldsymbol{x})\|_2^2+\boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x}+\frac{1}{2}\Delta\boldsymbol{x}^T\boldsymbol{H}\Delta\boldsymbol{x}$$

求右侧灯饰关于增量的导数并令它为0，得到：

$$\boldsymbol{H}\Delta\boldsymbol{x}=-\boldsymbol{J}^T$$

问题：迭代次数少，但是计算海塞矩阵（二阶导）太复杂了

高斯牛顿法

思想：对$f(x)$进行一阶泰勒展开。

$$f(\boldsymbol{x}+\Delta\boldsymbol{x}) \approx f(\boldsymbol{x})+\boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x}$$

最小二乘问题的平方误差演化为：

$$\begin{aligned}\frac{1}{2}\|f(\boldsymbol{x})+\boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x}\|^2 &= \frac{1}{2}(f(\boldsymbol{x})+\boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x})^T(f(\boldsymbol{x})+\boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x}) \\ &= \frac{1}{2}\left(\|f(\boldsymbol{x})\|_2^2+2f(\boldsymbol{x})^T\boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x}+\Delta\boldsymbol{x}^T\boldsymbol{J}(\boldsymbol{x})^T\boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x}\right)\end{aligned}$$

求关于增量的导并令其为0：

$$2\boldsymbol{J}(\boldsymbol{x})^Tf(\boldsymbol{x})+2\boldsymbol{J}(\boldsymbol{x})^T\boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x}=\boldsymbol{0}$$

可得到：

$$\begin{gathered}\boldsymbol{J}(\boldsymbol{x})^T\boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x}=-\boldsymbol{J}(\boldsymbol{x})^Tf(\boldsymbol{x}) \\ \boldsymbol{H}\Delta\boldsymbol{x}=\boldsymbol{g}\end{gathered}$$

这是因为，左侧利用$\boldsymbol{J}^{\boldsymbol{T}}\boldsymbol{J}$来近似二阶海塞矩阵，从而省略了二阶导求解。求解增量的迭代步骤如下：

1. 给定初始值x_0
2. 对于第k次迭代，求出当前的雅可比矩阵$\boldsymbol{J}\left(\boldsymbol{x}_k\right)$和误差$f(\boldsymbol{x}_k)$
3. 求解增量方程$\boldsymbol{H}\Delta\boldsymbol{x}=\boldsymbol{g}$
4. 若增量足够小则停止，否则，加上这个增量进行下一步迭代

问题：无法保证海塞矩阵可逆，因为近似的算法只有半正定性，可能出现奇异矩阵或病态情况，此时增量稳定性差，导致算法不收敛。

列文伯格-马夸尔特方法

给增量添加一个范围，称为**信赖区域**。这个范围定义了哪些情况下的二阶近似是有效的。

定义近似范围的好坏程度指标如下：

$$\rho=\frac{f(\boldsymbol{x}+\Delta\boldsymbol{x})-f(\boldsymbol{x})}{\boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x}}$$

它的实际含义是实际函数下降的值除以近似模型下降的值。理想情况下$\rho=1$。若值太小，则减小近似范围。若值太大，则增加近似范围。

具体操作：

1. 给定初始值 $\boldsymbol{x}_0$，以及初始优化半径 μ。

2. 对于第 k 次迭代，求解：

$$\min_{\Delta \boldsymbol{x}_k} \frac{1}{2}\|f(\boldsymbol{x}_k)+\boldsymbol{J}(\boldsymbol{x}_k)\Delta \boldsymbol{x}_k\|^2, \quad s.t. \|\boldsymbol{D}\Delta \boldsymbol{x}_k\|^2 \leq \mu,$$

   这里 μ 是信赖区域的半径，$\boldsymbol{D}$ 将在后文说明。

3. 计算 ρ。

4. 若 $\rho > \frac{3}{4}$，则 $\mu = 2\mu$；

5. 若 $\rho < \frac{1}{4}$，则 $\mu = 0.5\mu$；

6. 如果 ρ 大于某阈值，认为近似可行。令 $\boldsymbol{x}_{k+1} = \boldsymbol{x}_k + \Delta \boldsymbol{x}_k$。

7. 判断算法是否收敛。如不收敛则返回 2，否则结束。

在信赖区域内的优化，利用拉格朗日乘子转化为无约束优化：

$$\min_{\Delta \boldsymbol{x}_k} \frac{1}{2}\|f(\boldsymbol{x}_k)+\boldsymbol{J}(\boldsymbol{x}_k)\Delta \boldsymbol{x}_k\|^2 + \frac{\lambda}{2}\|\boldsymbol{D}\Delta \boldsymbol{x}\|^2.$$

由高斯牛顿法展开，增量方程仍为线性的：

$$\left(\boldsymbol{H}+\lambda \boldsymbol{D}^T\boldsymbol{D}\right)\Delta \boldsymbol{x} = \boldsymbol{g}$$

取$\boldsymbol{D} = \boldsymbol{I}$，则：

$$(\boldsymbol{H}+\lambda \boldsymbol{I})\Delta \boldsymbol{x} = \boldsymbol{g}$$

该方法可以保证增量方程的正定性，可以理解为一阶和二阶的混合，由参数控制权重。